

Estimativa da produção de energia de um parque eólico por meio de modelo estocástico

Diogo Daniel Panda Friggo

Universidade Federal do Rio Grande do Sul

Orientador: Carlo Requião da Cunha

Porto Alegre, 2019



Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

Objetivo

Prever geração de energia em dois passos:

- Fazer previsões sobre velocidade do vento

Objetivo

Prever geração de energia em dois passos:

- Fazer previsões sobre velocidade do vento
- Converter essa grandeza em energia por meio de uma curva de potência

Introdução

- Incerteza na velocidade do vento → incerteza na energia gerada

Introdução

- Incerteza na velocidade do vento → incerteza na energia gerada
- Demais variáveis melhor comportadas

Introdução

- Incerteza na velocidade do vento → incerteza na energia gerada
- Demais variáveis melhor comportadas
- Diferentes escalas de previsão para diferentes agentes
 - Operador de subestação: escala horária

Introdução

- Incerteza na velocidade do vento → incerteza na energia gerada
- Demais variáveis melhor comportadas
- Diferentes escalas de previsão para diferentes agentes
 - Operador de subestação: escala horária
 - Dono do parque eólico: escala mensal/anual para acordos de entrega de energia e minutal/horária para monitoramento de componentes

Introdução

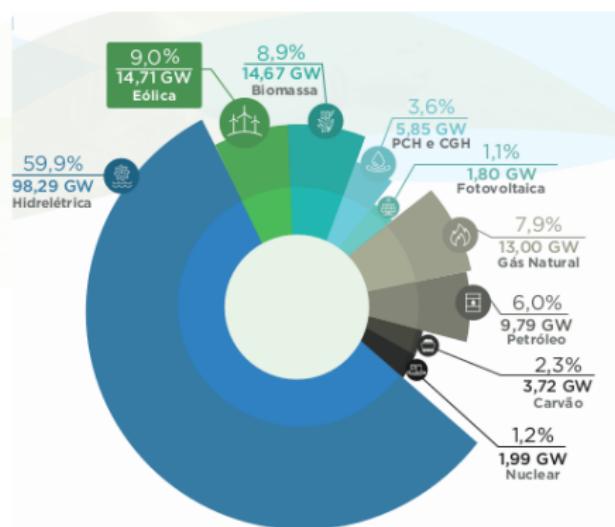
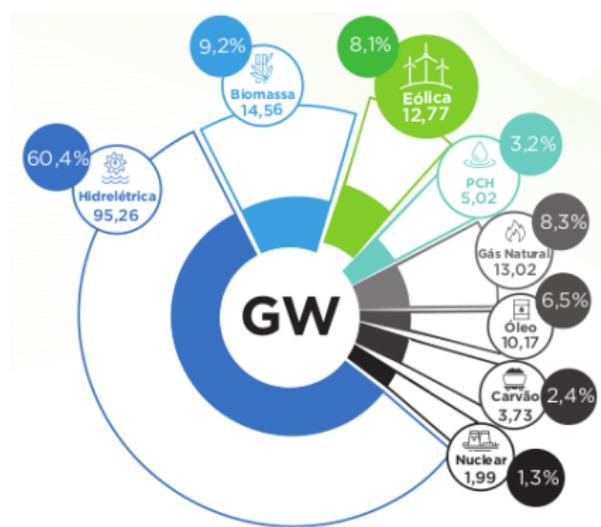
- Incerteza na velocidade do vento → incerteza na energia gerada
- Demais variáveis melhor comportadas
- Diferentes escalas de previsão para diferentes agentes
 - Operador de subestação: escala horária
 - Dono do parque eólico: escala mensal/anual para acordos de entrega de energia e minutal/horária para monitoramento de componentes
 - Fundo de investimento: escala quadrienal

Energia eólica

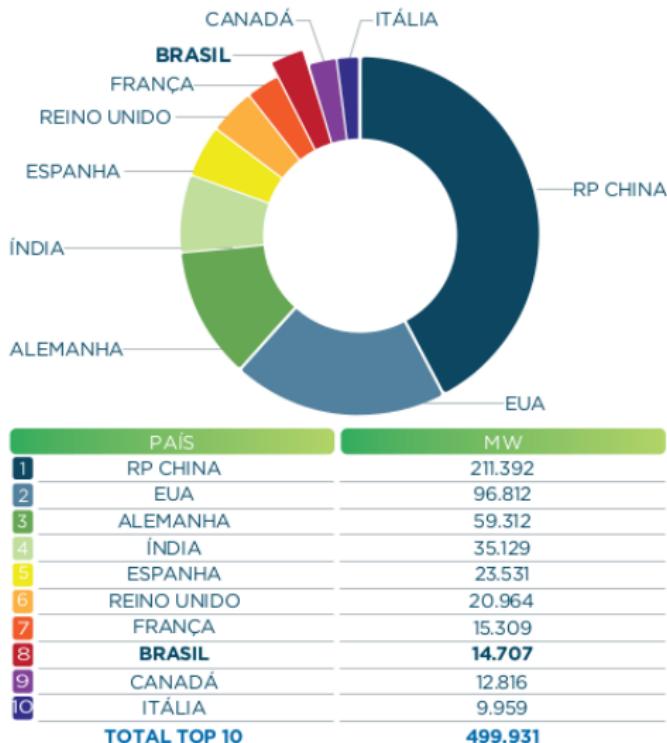
- Alternativa a fontes de energia não-renováveis
- Capaz de suprir boa parte da demanda do país
- Economicamente viável
- Décadas de experiência acumulada

Composição da matriz energética brasileira 2017-2018

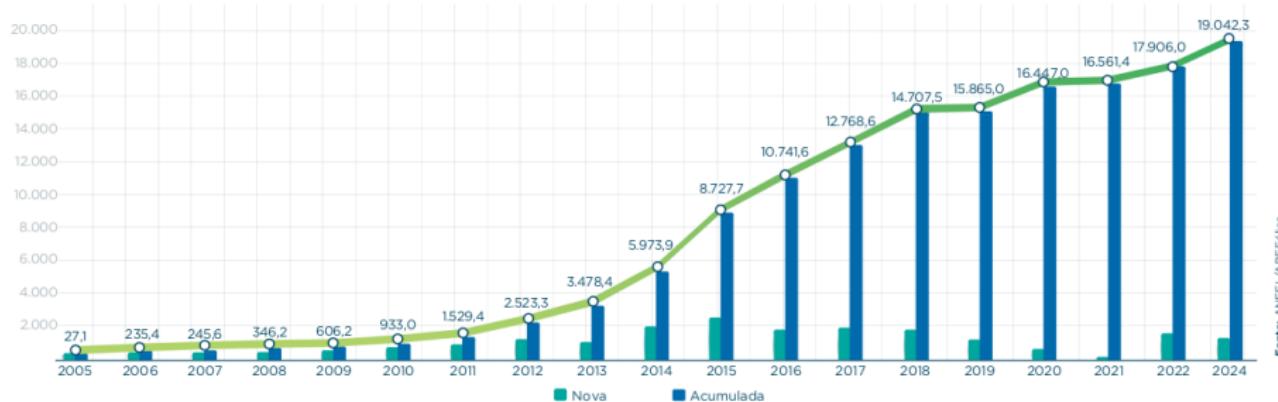
O investimento em energia renovável vem crescendo



Ranking de capacidade eólica instalada acumulada



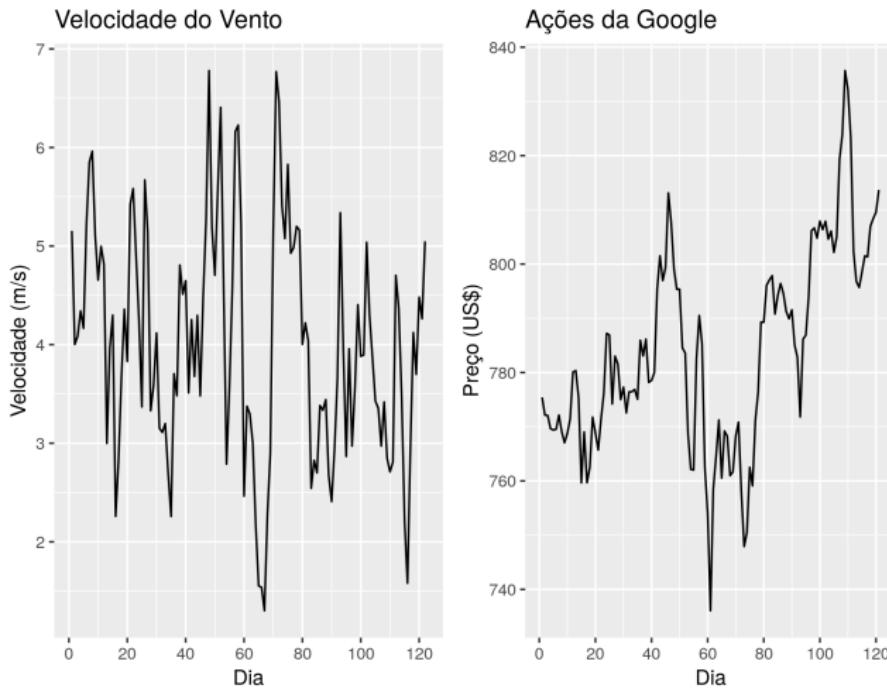
Evolução da capacidade instalada de parques eólicos no Brasil



Fonte: ANEEL/ABEEólica

Variáveis estocásticas

O arcabouço teórico desenvolvido para estudar séries financeiras pode ser aplicado no estudo de outras séries estocásticas.



Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

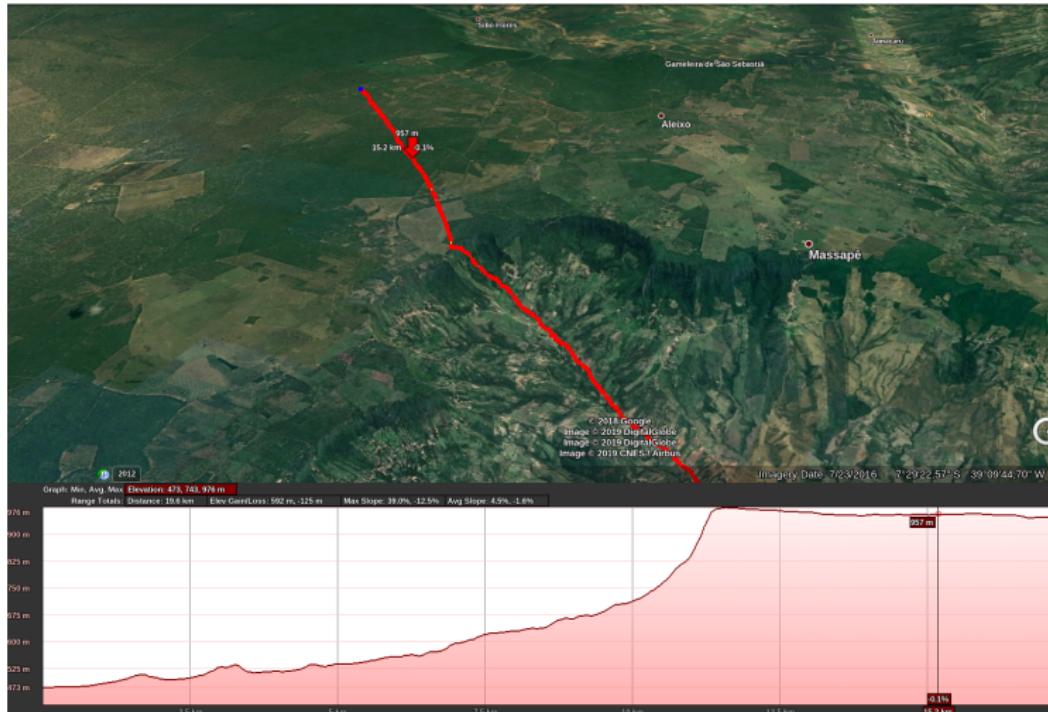
3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

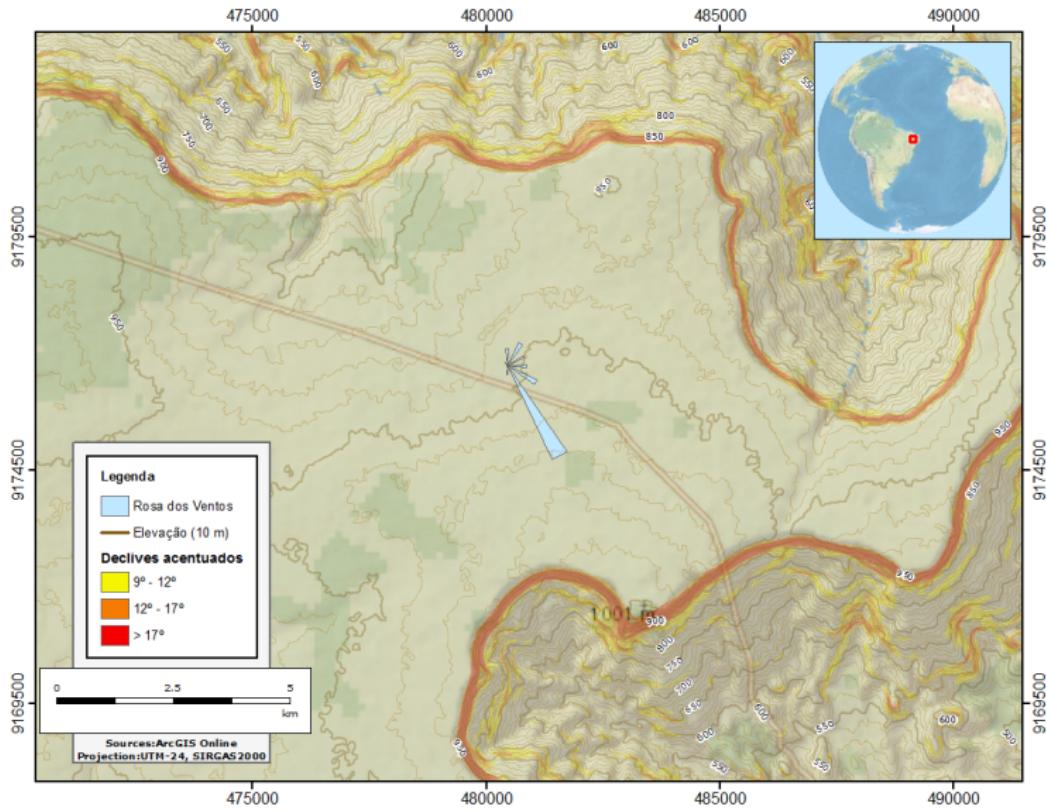
4 Conclusão

- Conversão em energia
- Validação com outras séries

Variação da elevação na direção preferencial de escoamento do vento.



Topografia



Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

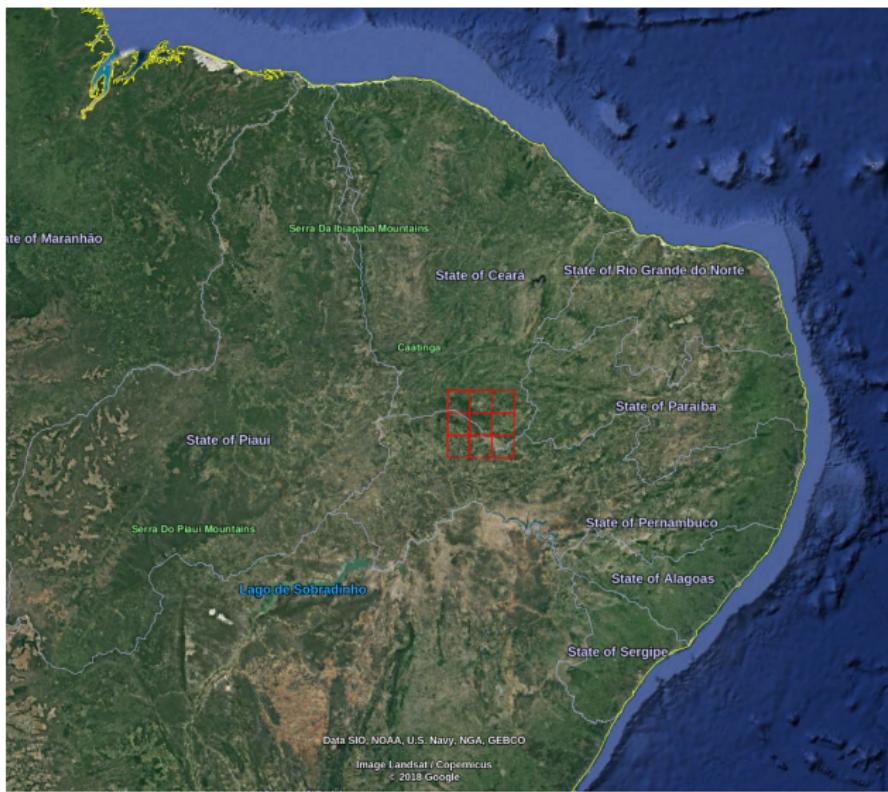
3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

ERA 5



- Medições por satélite

- Medições por satélite
- For correlação com torres no solo

ERA 5

- Medições por satélite
- For correlação com torres no solo
- Aperfeiçoada em relação a ERA-Interim e MERRA2

- Medições por satélite
- For correlação com torres no solo
- Aperfeiçoadas em relação a ERA-Interim e MERRA2
- Altura de medição a 100 m

- Medição por satélite
- For correlação com torres no solo
- Aperfeiçoada em relação a ERA-Interim e MERRA2
- Altura de medição a 100 m
- Dados horários

ERA 5

- Medições por satélite
- For correlação com torres no solo
- Aperfeiçoada em relação a ERA-Interim e MERRA2
- Altura de medição a 100 m
- Dados horários
- Resolução espacial de 30 km

- Medições por satélite
- For correlação com torres no solo
- Aperfeiçoada em relação a ERA-Interim e MERRA2
- Altura de medição a 100 m
- Dados horários
- Resolução espacial de 30 km
- 20 anos de dados

Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

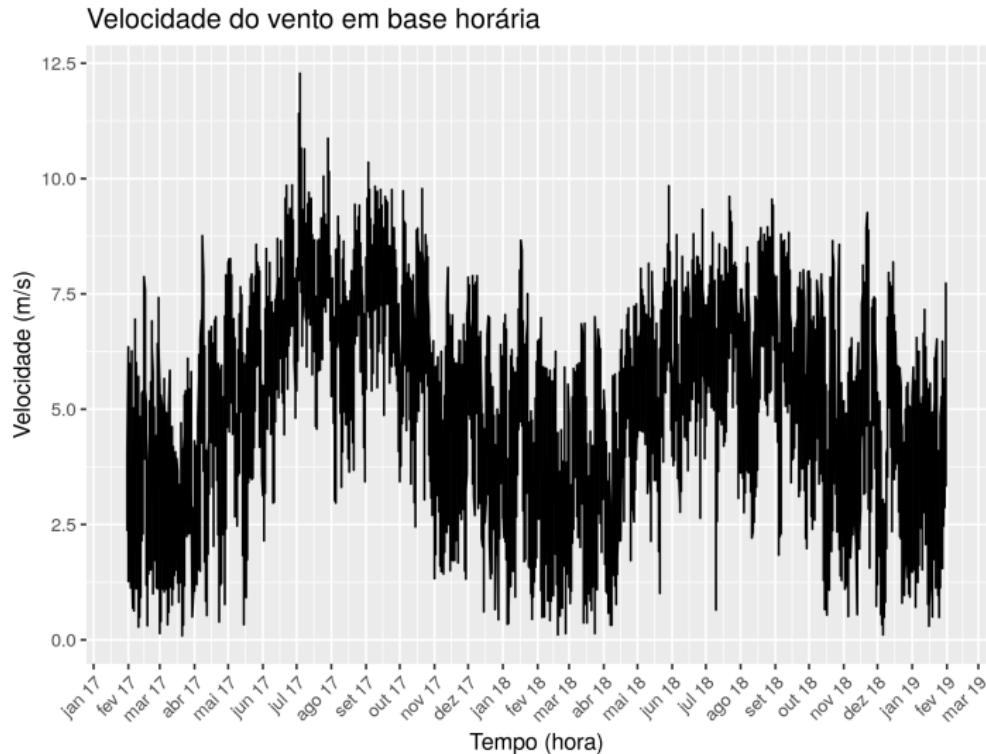
3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

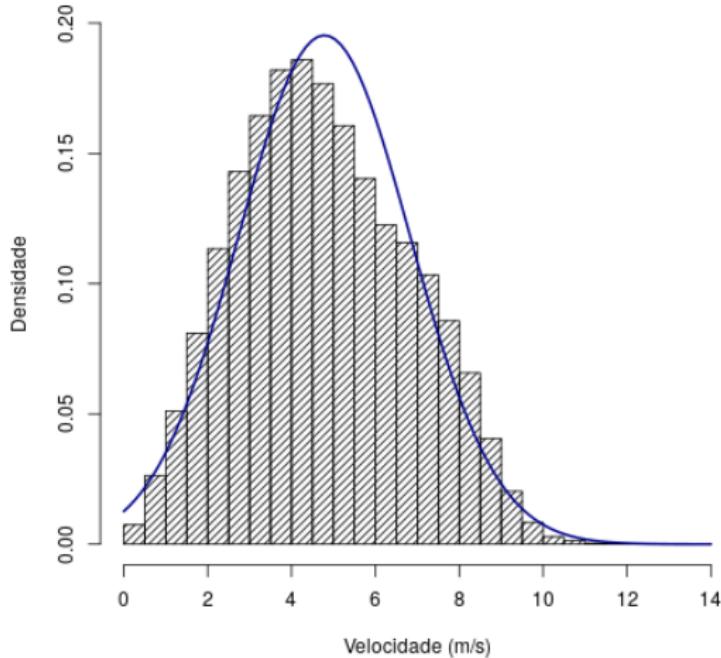
- Conversão em energia
- Validação com outras séries

Velocidade do vento registrada por satélite na região de interesse nos anos de 2017 e 2018



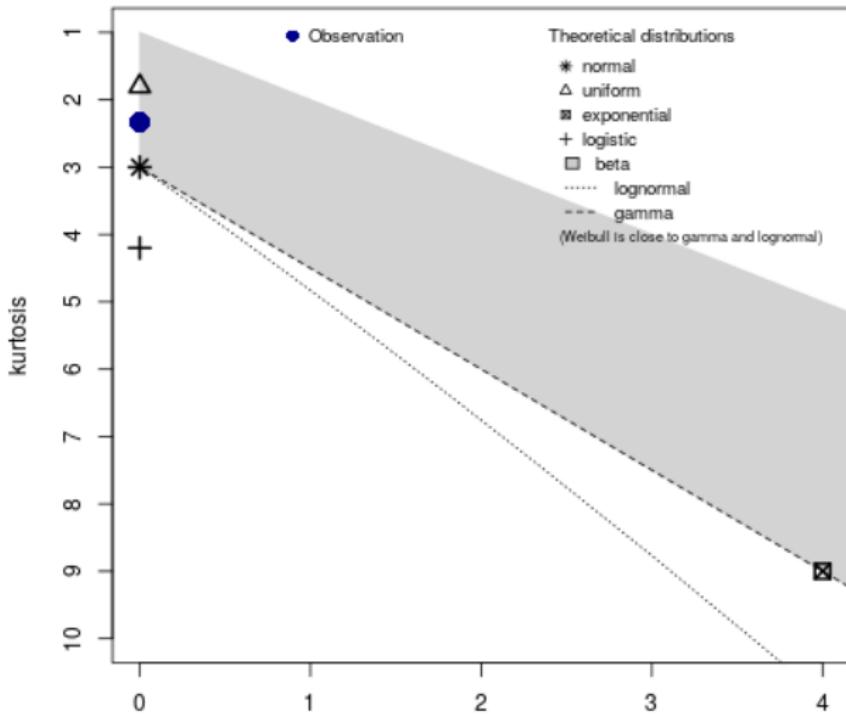
Histograma de velocidades do nó noroeste da série de dados modelo.

Curva normal superposta ao histograma de velocidades

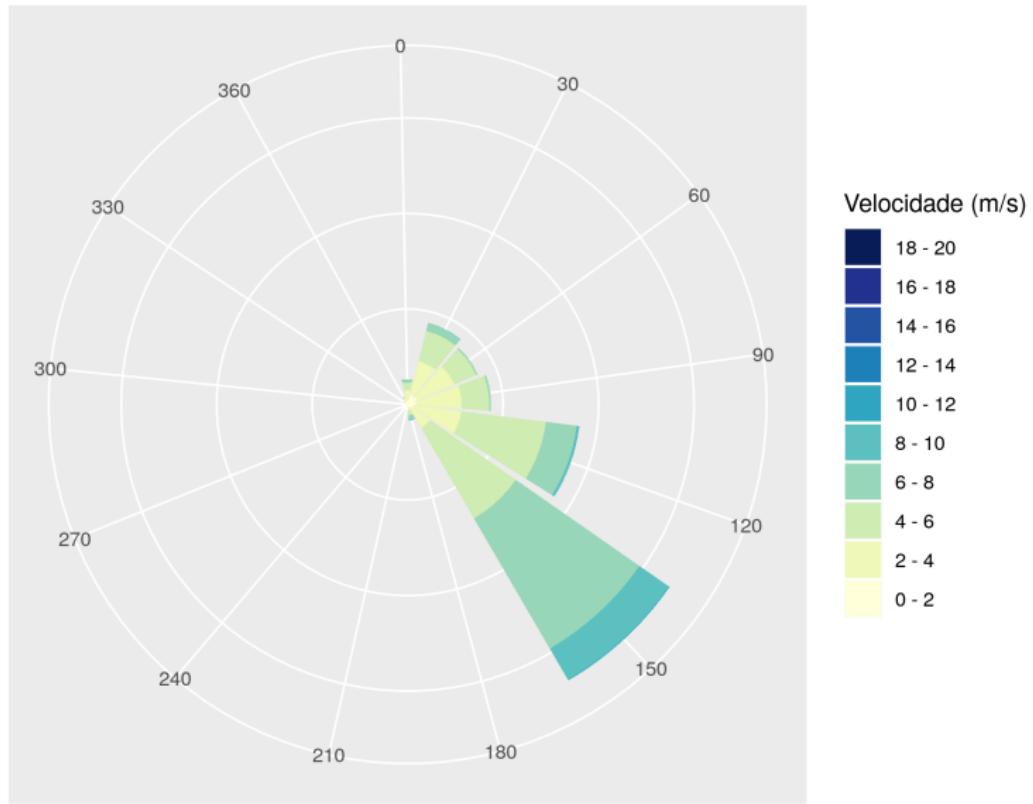


Distribuição de cauda longa

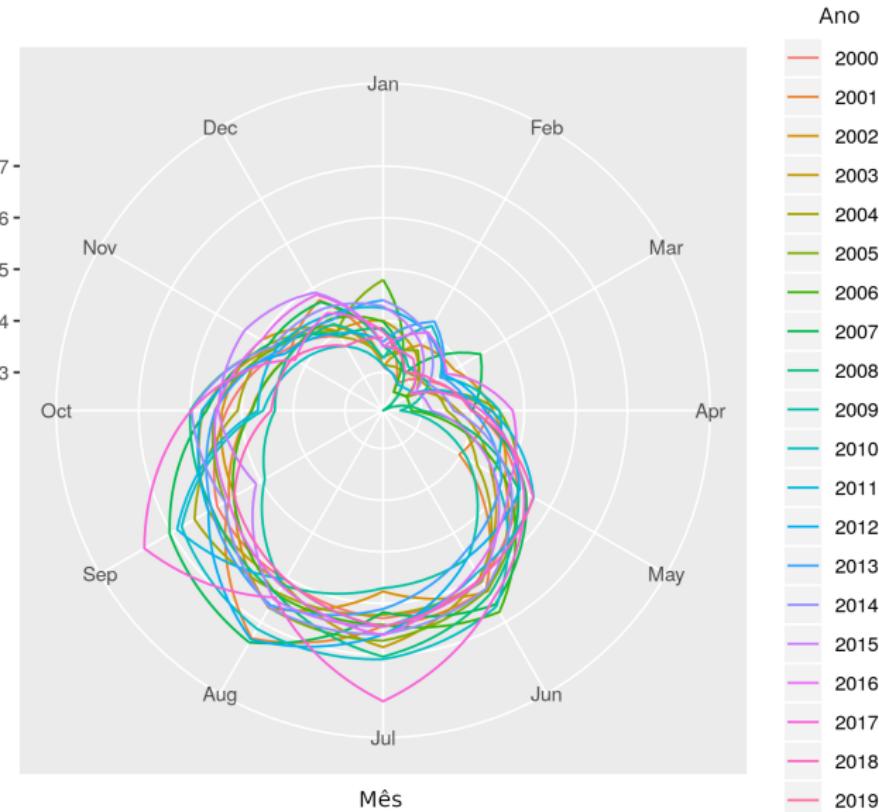
Cullen and Frey graph



Direção: rosa dos ventos de longo prazo



Sazonalidade



Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

AR

$$y_t' = c + \phi_1 y_{t-1}' + \cdots + \phi_p y_{t-p}'$$

ARIMA

AR

$$y_t' = c + \phi_1 y_{t-1}' + \cdots + \phi_p y_{t-p}'$$

MA

$$y_t' = \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t$$

ARIMA

AR

$$y_t' = c + \phi_1 y_{t-1}' + \cdots + \phi_p y_{t-p}'$$

MA

$$y_t' = \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t$$

ARIMA

$$y_t' = c + \phi_1 y_{t-1}' + \cdots + \phi_p y_{t-p}' + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t$$

Onde y_t' representa a série de entrada y_t após feitas d diferenciações de modo a torná-la estacionária (parâmetro correspondente ao I em ARIMA)

Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Teste os modelos comparando seus valores de AIC

Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Faça um gráfico dos dados

- ➌ Verifique se os dados são estacionários
- ➍ Verifique se existem sazonais
- ➎ Verifique se existem outliers
- ➏ Verifique se existem estruturas de sazonalidade
- ➐ Teste os modelos comparando seus valores de AIC

Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Faça um gráfico dos dados
- ➌ Identifique comportamentos atípicos

- ➎ Teste os modelos comparando seus valores de AIC

Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Faça um gráfico dos dados
- ➌ Identifique comportamentos atípicos
- ➍ Identifique padrões

- ➋ Teste os modelos comparando seus valores de AIC

Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Faça um gráfico dos dados
- ➌ Identifique comportamentos atípicos
- ➍ Identifique padrões
- ➎ A variância parece ser constante ao longo da série?
 - ➏ Não? Aplique uma transformação Box-Cox para estabilizar a variância até que a série aparente ser estacionária
- ➏ Teste os modelos comparando seus valores de AIC

Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Faça um gráfico dos dados
- ➌ Identifique comportamentos atípicos
- ➍ Identifique padrões
- ➎ A variância parece ser constante ao longo da série?
 - ➏ Não? Aplique uma transformação Box-Cox para estabilizar a variância até que a série aparente ser estacionária
- ➏ Analise os gráficos ACF e PACF para identificar prováveis modelos
- ➐ Teste os modelos comparando seus valores de AIC

Box-Jenkins: como encontrar p,d,q?

- ① Etapa inicial
- ② Faça um gráfico dos dados
- ③ Identifique comportamentos atípicos
- ④ Identifique padrões
- ⑤ A variância parece ser constante ao longo da série?
 - Não? Aplique uma transformação Box-Cox para estabilizar a variância até que a série aparente ser estacionária
- ⑥ Analise os gráficos ACF e PACF para identificar prováveis modelos
- ⑦ Teste os modelos comparando seus valores de AIC
- ⑧ Verifique os resíduos por ACF e por Ljung-Box

Box-Jenkins: como encontrar p,d,q?

- ① Etapa inicial
- ② Faça um gráfico dos dados
- ③ Identifique comportamentos atípicos
- ④ Identifique padrões
- ⑤ A variância parece ser constante ao longo da série?
 - Não? Aplique uma transformação Box-Cox para estabilizar a variância até que a série aparente ser estacionária
- ⑥ Analise os gráficos ACF e PACF para identificar prováveis modelos
- ⑦ Teste os modelos comparando seus valores de AIC
- ⑧ Verifique os resíduos por ACF e por Ljung-Box
- ⑨ Os resíduos se aproximam de ruído branco?
 - Não? Volte para a etapa 6

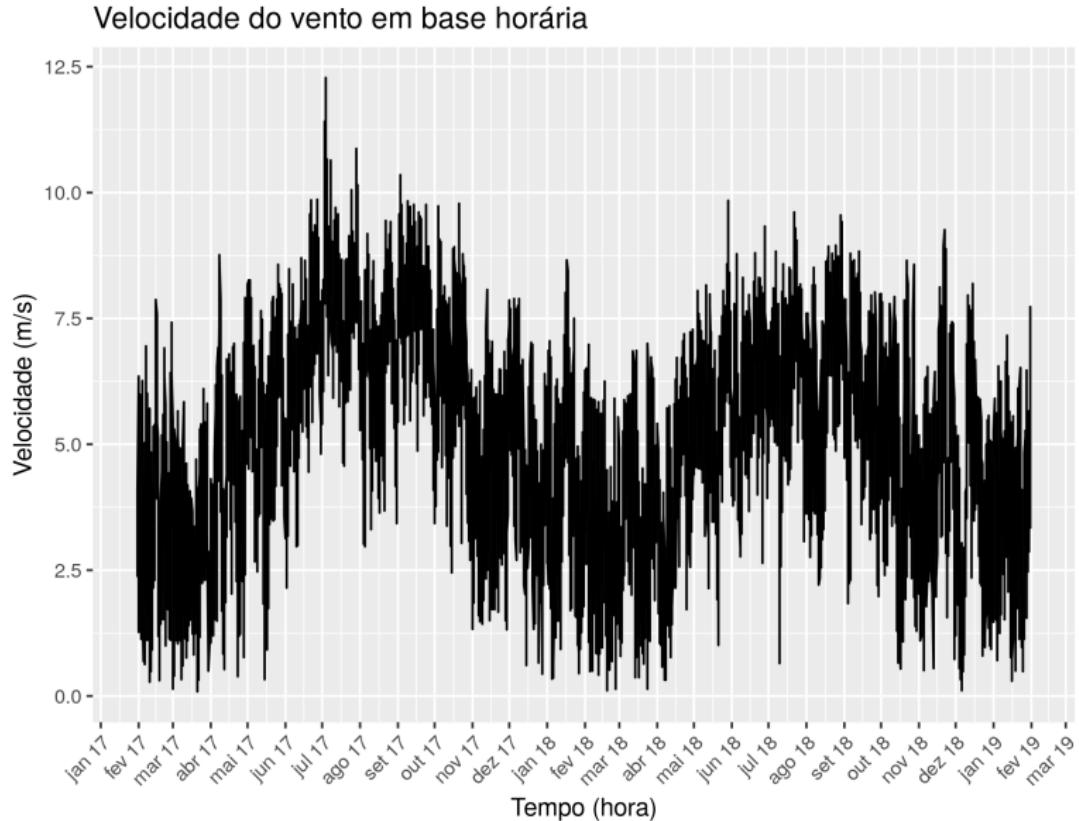
Box-Jenkins: como encontrar p,d,q?

- ① Etapa inicial
- ② Faça um gráfico dos dados
- ③ Identifique comportamentos atípicos
- ④ Identifique padrões
- ⑤ A variância parece ser constante ao longo da série?
 - Não? Aplique uma transformação Box-Cox para estabilizar a variância até que a série aparente ser estacionária
- ⑥ Analise os gráficos ACF e PACF para identificar prováveis modelos
- ⑦ Teste os modelos comparando seus valores de AIC
- ⑧ Verifique os resíduos por ACF e por Ljung-Box
- ⑨ Os resíduos se aproximam de ruído branco?
 - Não? Volte para a etapa 6
- ⑩ Estime parâmetros

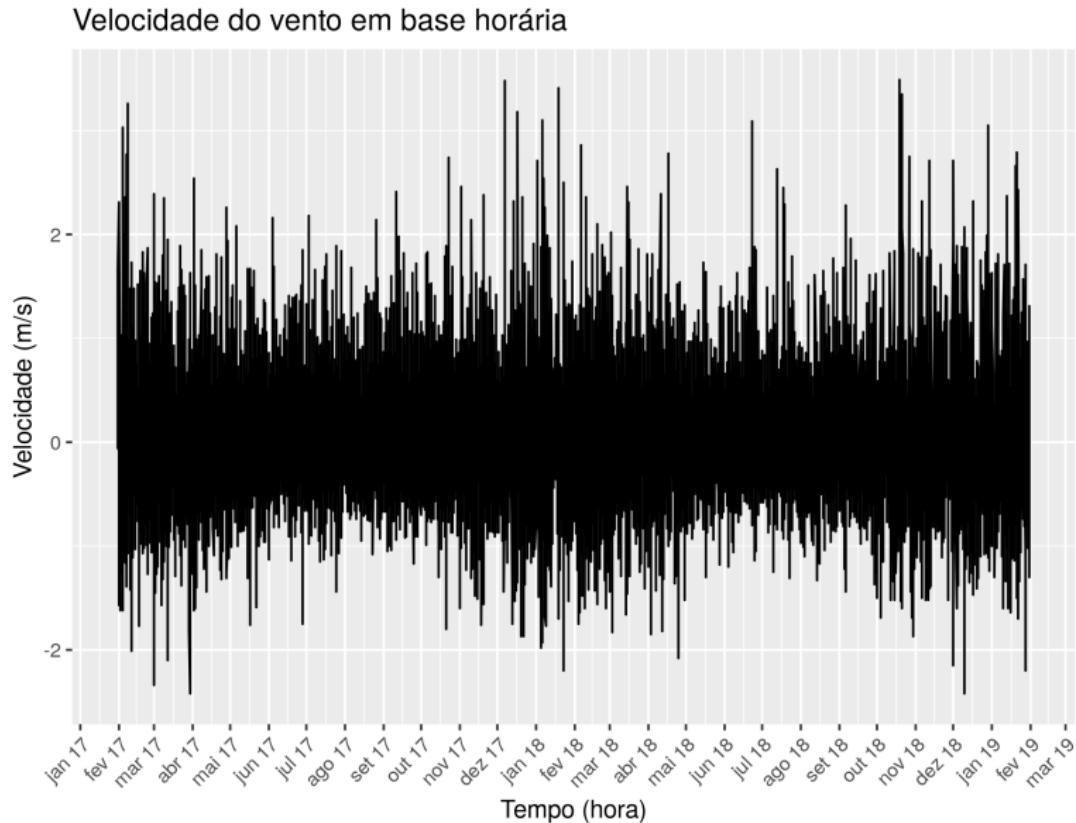
Box-Jenkins: como encontrar p,d,q?

- ➊ Etapa inicial
- ➋ Faça um gráfico dos dados
- ➌ Identifique comportamentos atípicos
- ➍ Identifique padrões
- ➎ A variância parece ser constante ao longo da série?
 - Não? Aplique uma transformação Box-Cox para estabilizar a variância até que a série aparente ser estacionária
- ➏ Analise os gráficos ACF e PACF para identificar prováveis modelos
- ➐ Teste os modelos comparando seus valores de AIC
- ➑ Verifique os resíduos por ACF e por Ljung-Box
- ➒ Os resíduos se aproximam de ruído branco?
 - Não? Volte para a etapa 6
- ➓ Estime parâmetros
- ➔ Faça previsões

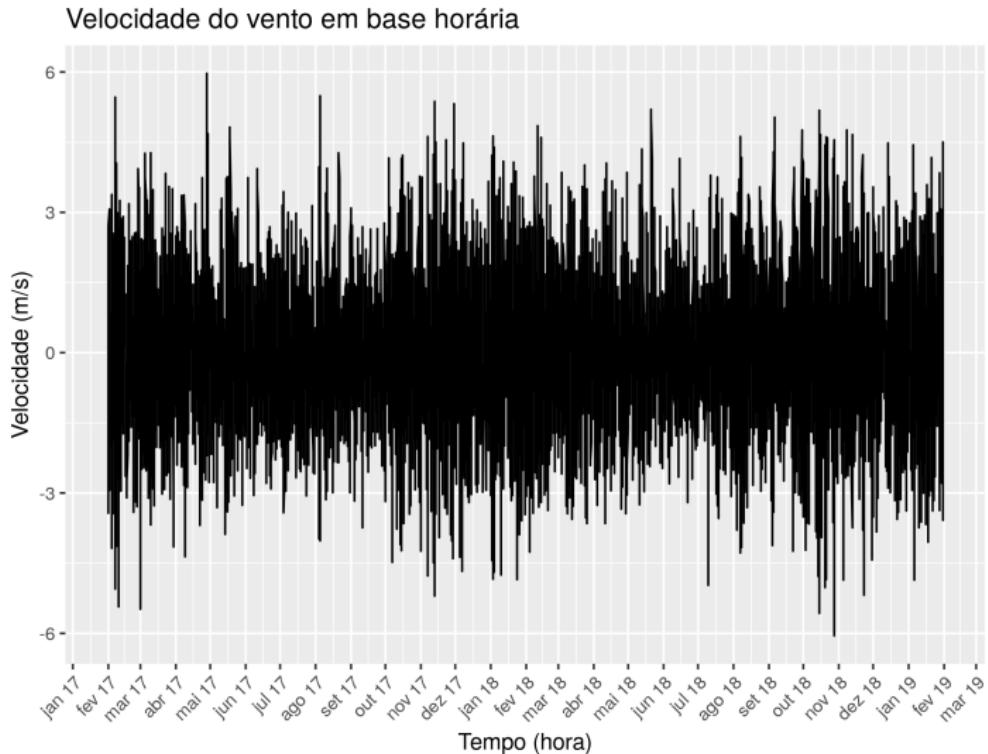
Análise visual: últimos dois anos da série de vento



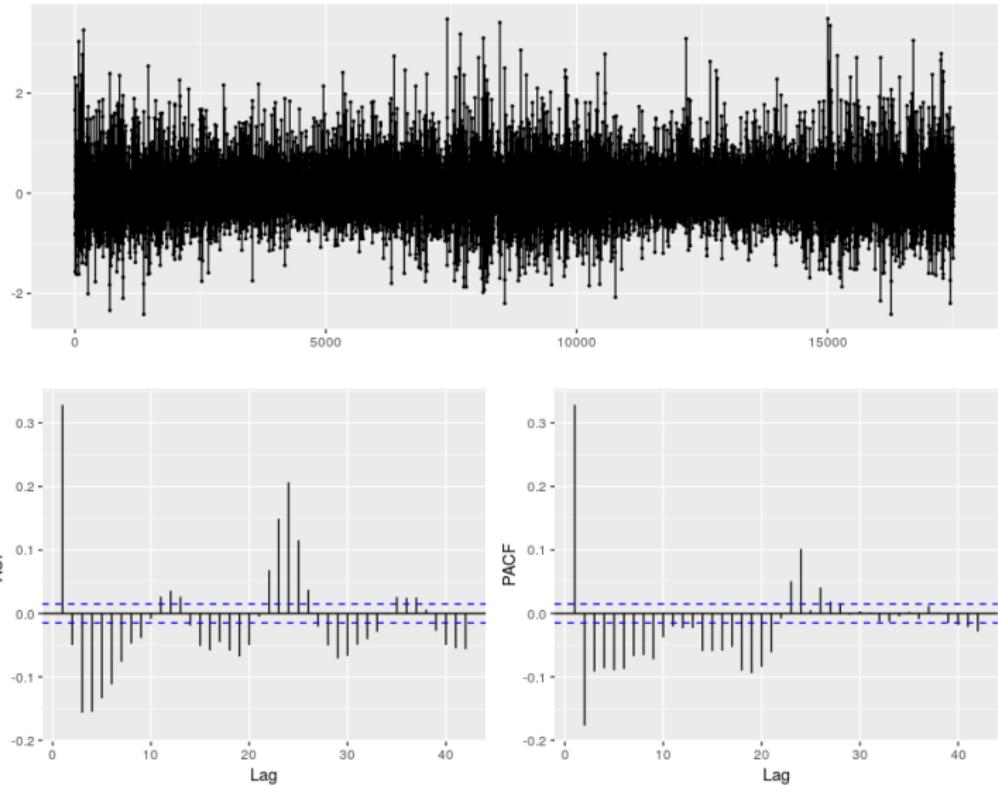
Sazonalidade removida por simples diferença



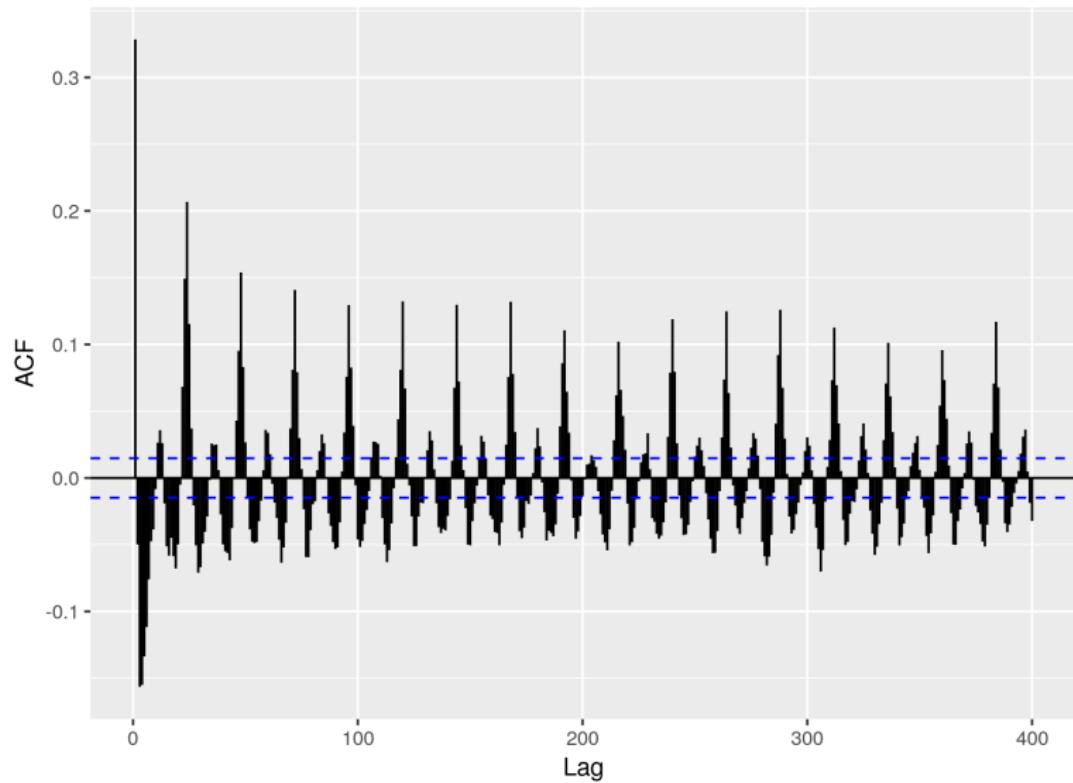
Estabilização da variância por meio de uma transformação de Box-Cox



PACF: atenuação aparente



Memória longa!



Memória Longa de Curto-Prazo

- Modelo utilizando redes neurais
- Resultado insatisfatório
- Longo tempo de treinamento

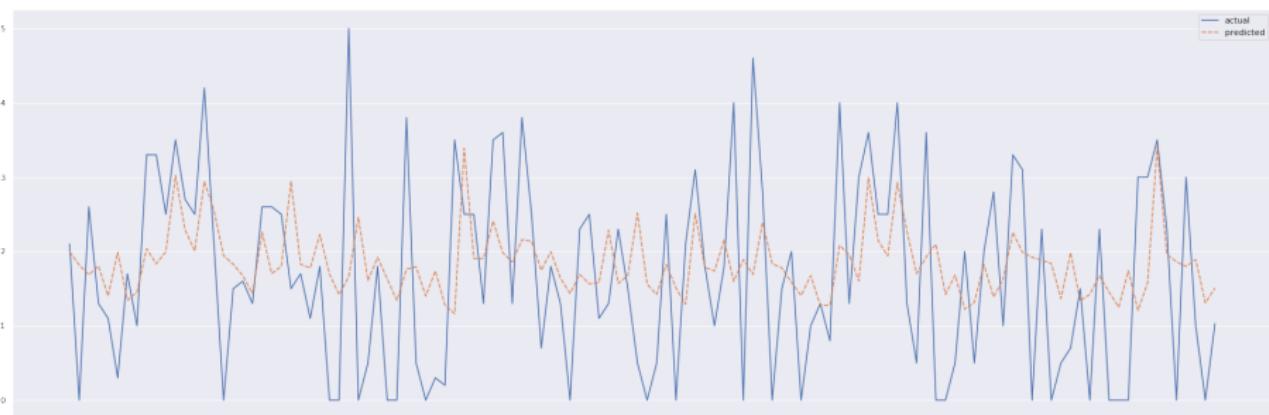
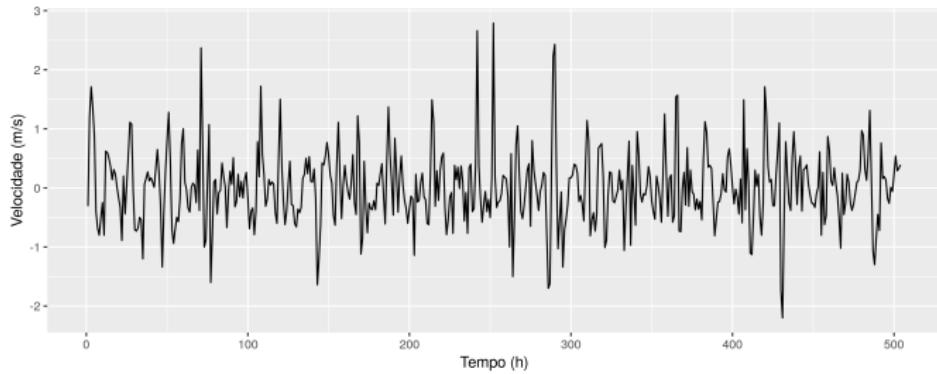
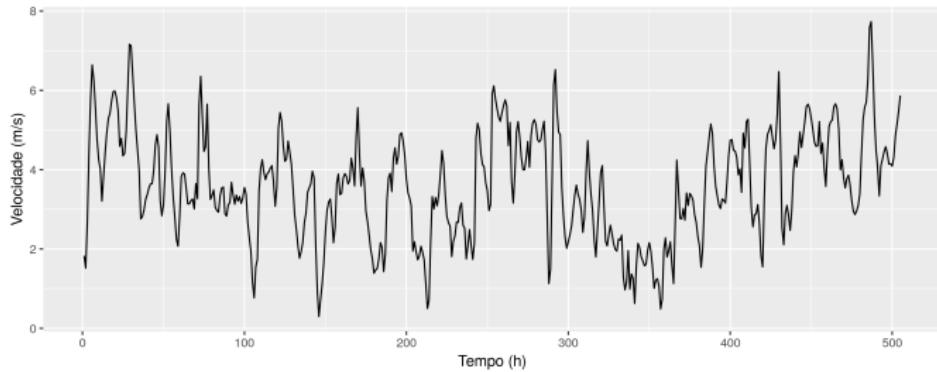
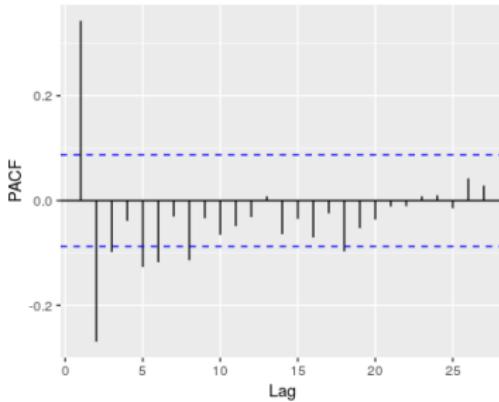
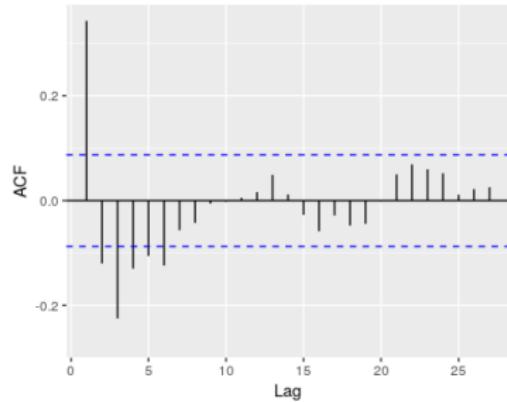
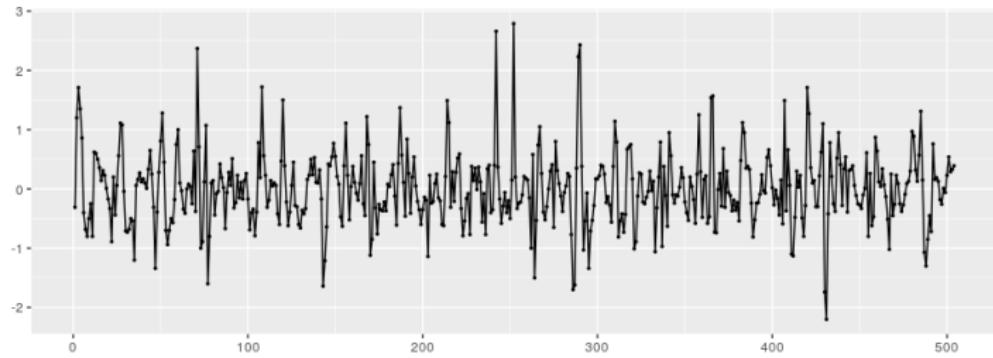


Figure: Curva em azul: dados medidos. Curva em laranja: dados previstos pelo modelo

Mudança de abordagem: janela de dados (diferenciação)



Novas funções de autocorrelação



Mensurando o erro de previsão: $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$

Erro médio absoluto (MAE)

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |e_t|$$

Mensurando o erro de previsão: $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$

Erro médio absoluto (MAE)

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |e_t|$$

Raíz do quadrado da média do erro (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T e_t^2}$$

Mensurando o erro de previsão: $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$

Erro médio absoluto (MAE)

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |e_t|$$

Raíz do quadrado da média do erro (RMSE)

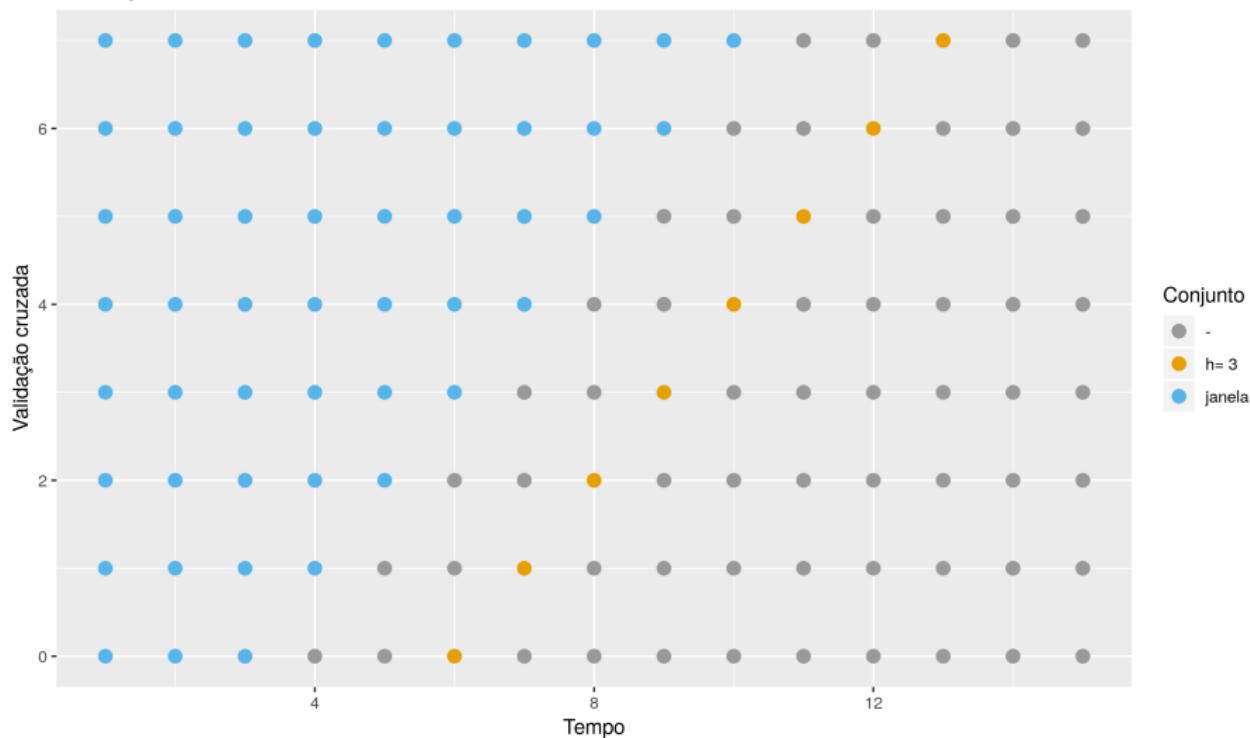
$$\text{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T e_t^2}$$

Erro absoluto médio escalonado (MASE)

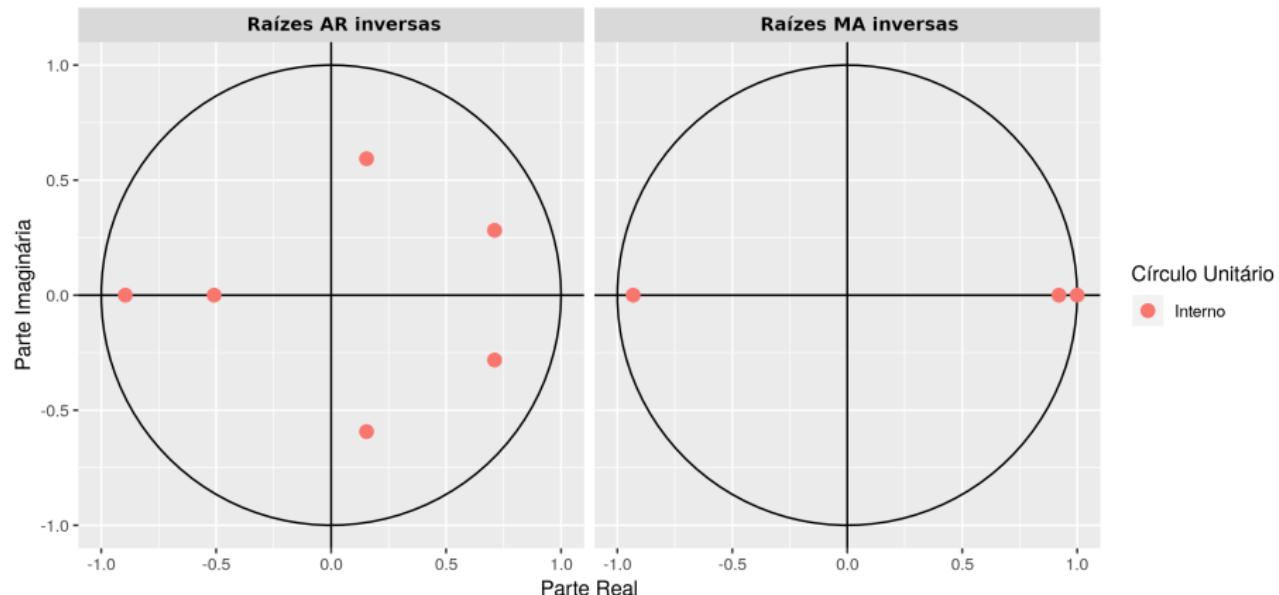
$$\text{MASE} = \frac{\frac{1}{T} \sum_{t=1}^T |e_t|}{\frac{1}{T-1} \sum_{t=2}^T |y_t - y_{t-1}|}$$

Validação cruzada: conjunto de treinamento e de teste

Validação cruzada com horizonte de previsão $h=3$

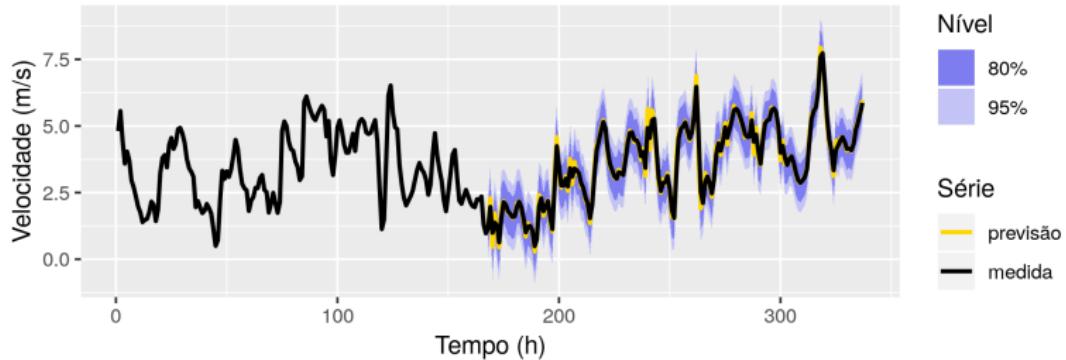


Estabilidade: regime estacionário e inversibilidade

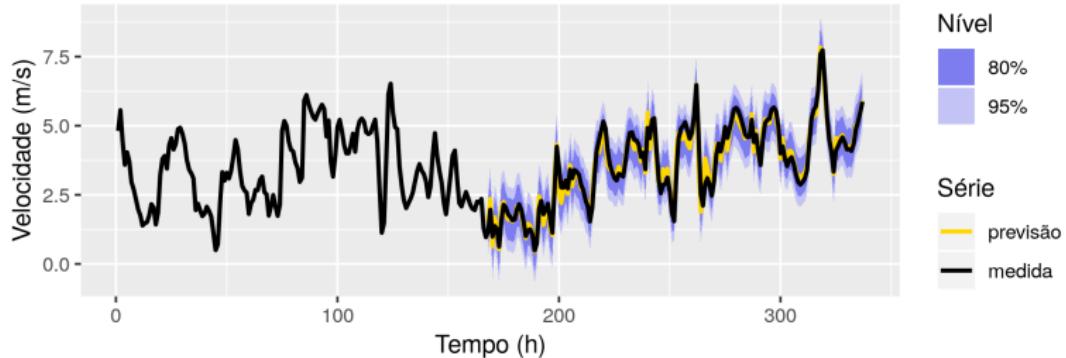


Previsões com modelo ARIMA

Previsão de 336 horas passo= 1 hora , ARIMA(1,1,1) com janela 168 horas

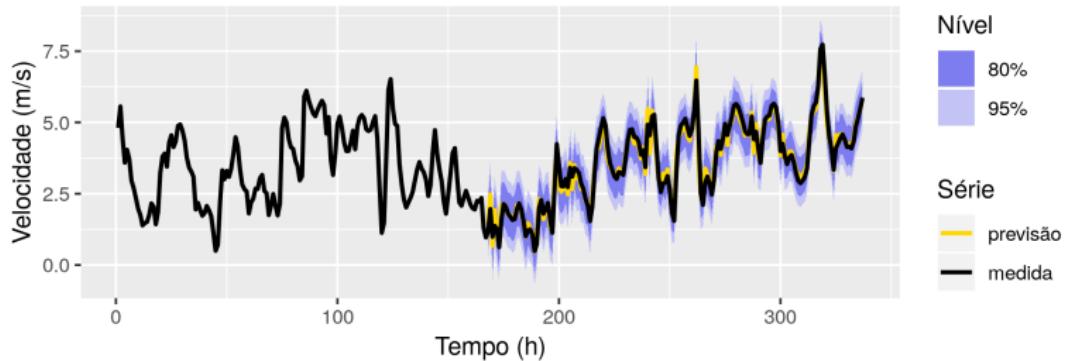


Previsão de 336 horas passo= 1 hora , ARIMA(2,1,1) com janela 168 horas

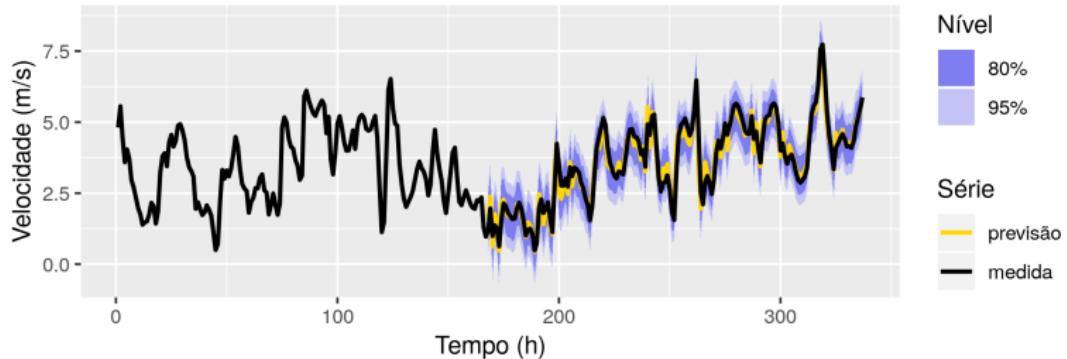


Previsões com modelo ARIMA

Previsão de 336 horas passo= 1 hora , ARIMA(1,1,2) com janela 168 horas



Previsão de 336 horas passo= 1 hora , ARIMA(2,1,3) com janela 168 horas



Medidas de erro

ARIMA(p,d,q)	ME	RMSE	MAE	MPE	MASE
1,1,1	-0.008	0.223	0.162	0.382	5.731
2,1,1	0.008	0.297	0.228	-0.756	7.622
1,1,2	0.016	0.249	0.187	-0.839	6.152
2,1,3	0.0158	0.319	0.238	-0.838	7.968

Table: Medidas de erro para 4 modelos ARIMA aplicados à séries modelo.

Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

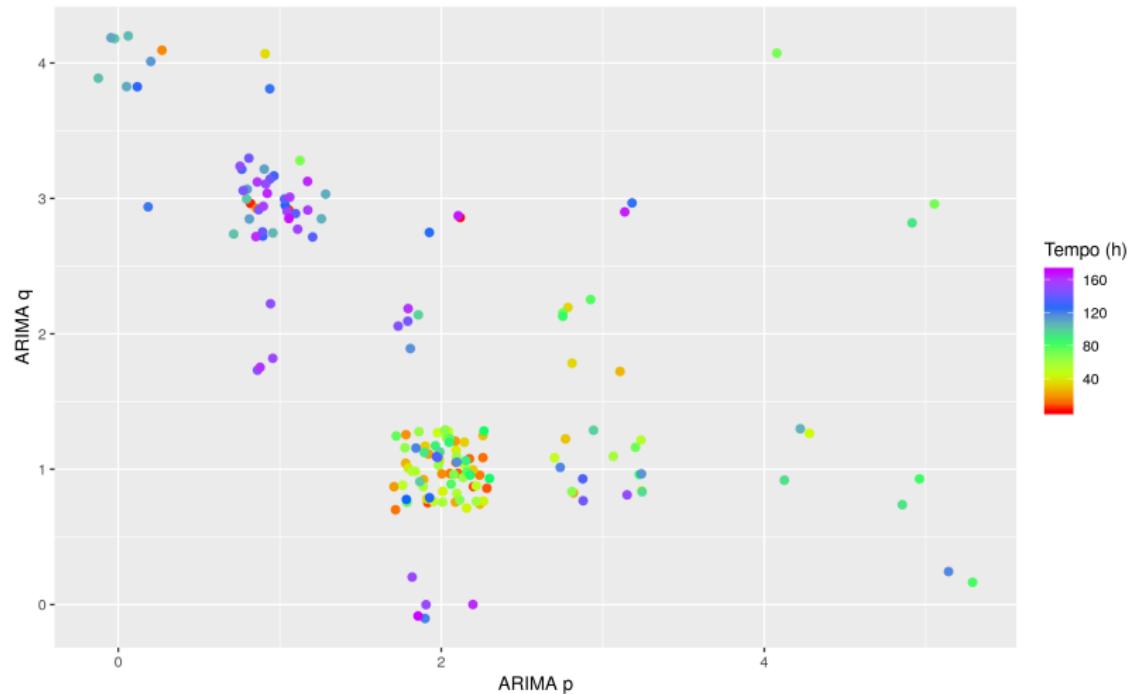
Modelo Autorregressivo Variável

- Um único modelo ARIMA estático não é capaz de capturar a dinâmica da série temporal

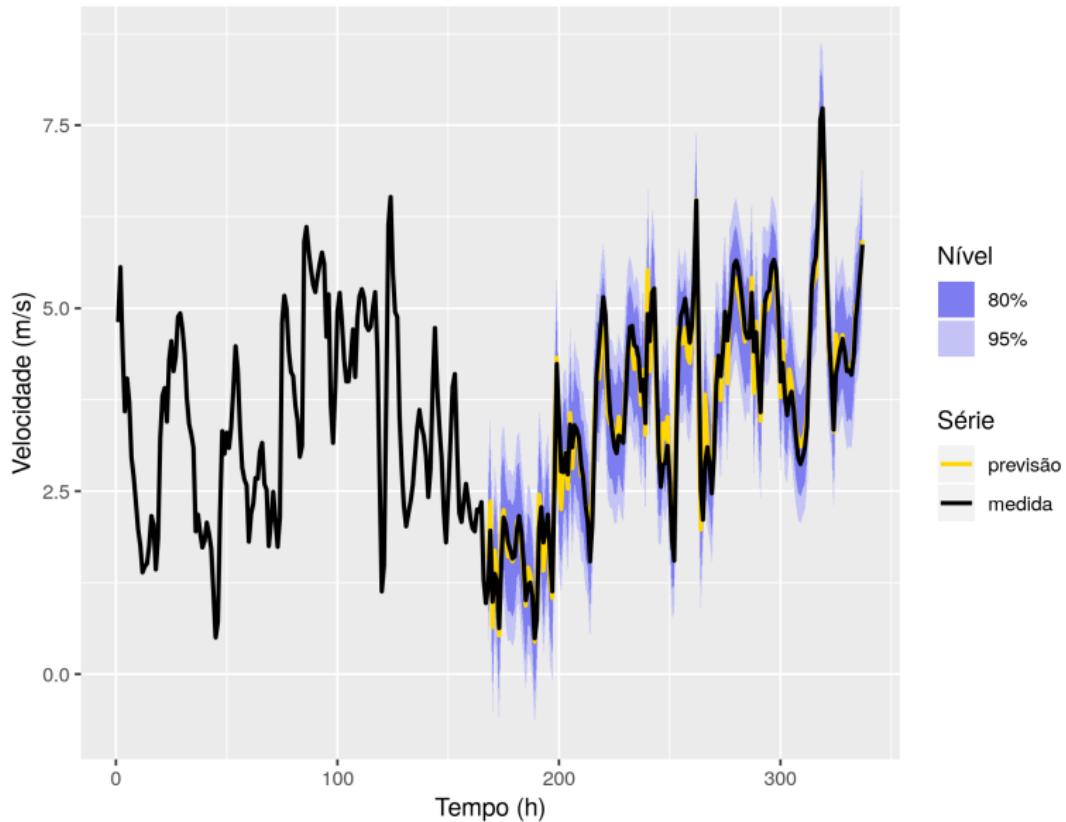
Modelo Autorregressivo Variável

- Um único modelo ARIMA estático não é capaz de capturar a dinâmica da série temporal
- Diferentes janelas de dados apresentam diferentes parâmetros p,q ótimos

Evolução dos parâmetros p e q de um modelo ARIMA ao longo do tempo



Previsão utilizando modelo ARIMA adaptativo



Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

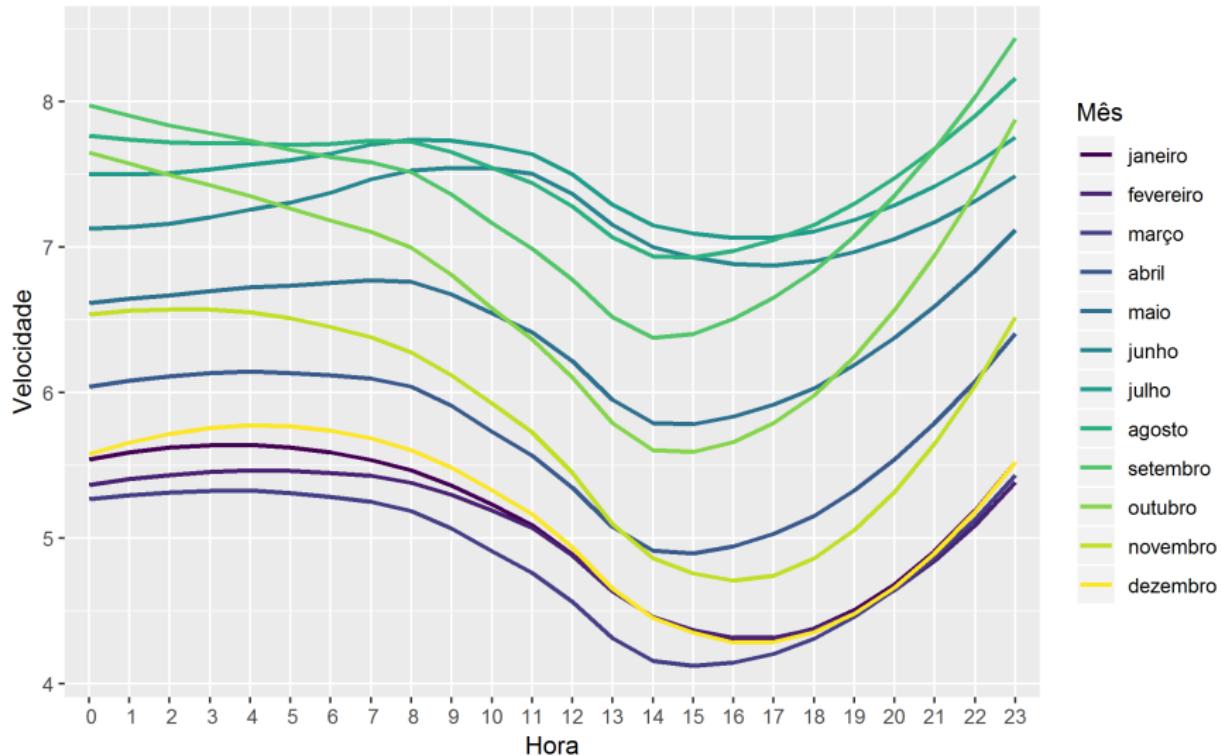
3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

Incorporando a variância



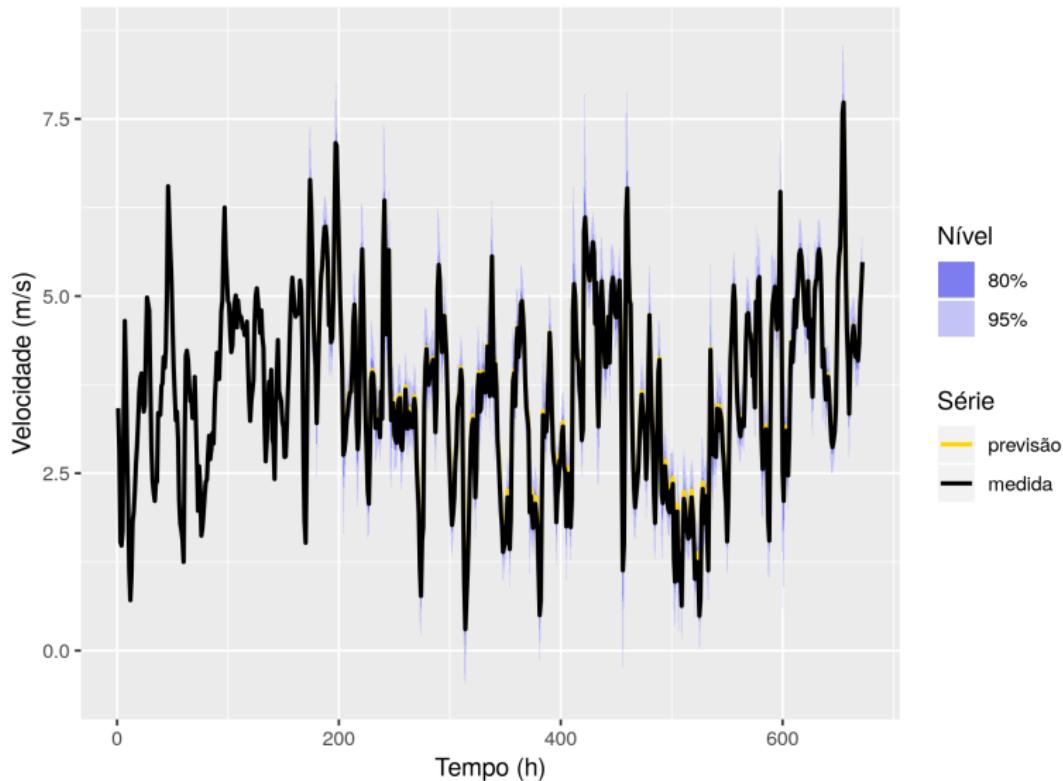
GARCH

$$\sigma_t^2 = \underbrace{\beta_1 \sigma_{t-1}^2 + \cdots + \beta_p \sigma_{t-p}^2}_{\text{autorregressão}} + \underbrace{\omega + \alpha_1 \varepsilon_{t-1}^2 + \cdots + \alpha_q \varepsilon_{t-q}^2}_{\text{média móvel}}$$

$$\sigma_t^2 = \sum_{i=1}^q \beta_i \sigma_{t-i}^2 + \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2$$

GARCH: previsão em base horária

GARCH(1,1) com janela de 50 horas e passo de 1 hora



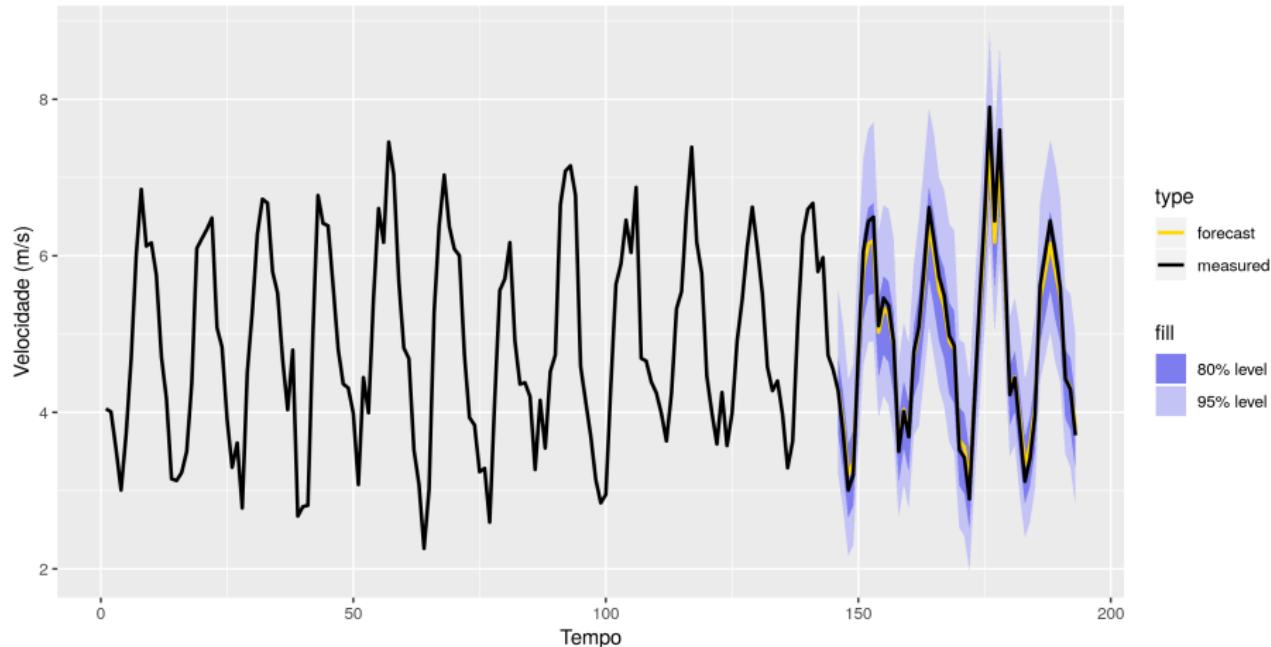
Comparação com resultados anteriores

Modelo	ME	RMSE	MAE	MPE	MASE
GARCH(1,1)	-0.042	0.065	0.051	-2.451	2.592
ARIMA(1,1,1)	-0.008	0.223	0.162	0.382	5.731
ARIMA(2,1,1)	0.008	0.297	0.228	-0.756	7.622
ARIMA(1,1,2)	0.016	0.249	0.187	-0.839	6.152
ARIMA(2,1,3)	0.0158	0.319	0.238	-0.838	7.968

Table: Medidas de erro para 4 modelos ARIMA aplicados à séries modelo.

GARCH: previsão em base mensal

GARCH(1,1) com janela de 4 meses e passo de 1 mês



Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

O cálculo da potência

$$P = \frac{1}{2} \rho \frac{\pi D^2}{4} \nu^3 C_p \eta$$

P = potência elétrica na altura do cubo rotor [W]

ρ = densidade do ar $\left[\frac{kg}{m^3} \right]$

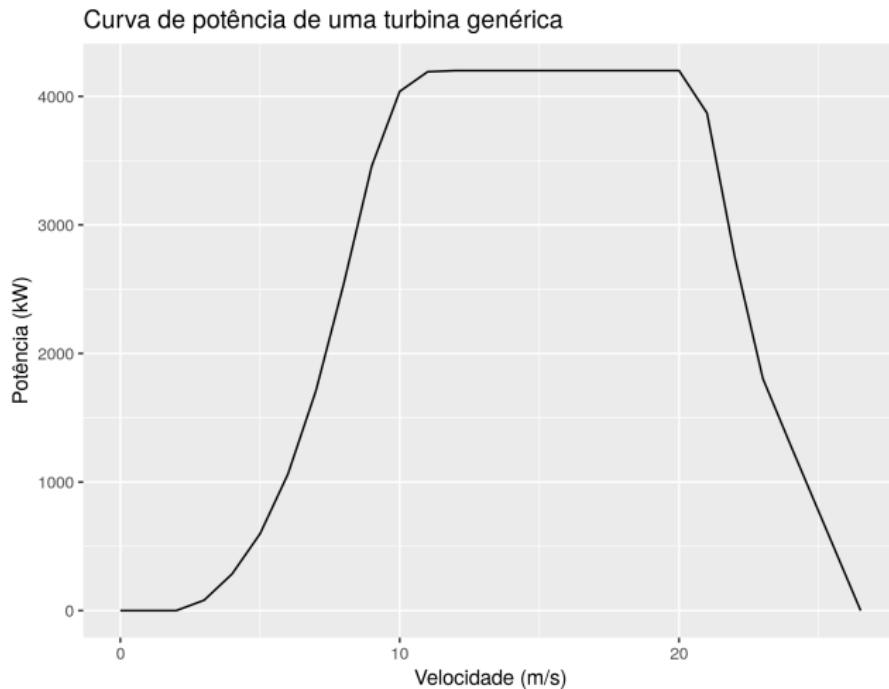
D = diâmetro do rotor [m]

ν = velocidade do vento $\left[\frac{m}{s} \right]$

C_p = coeficiente aerodinâmico de potência do rotor [W]

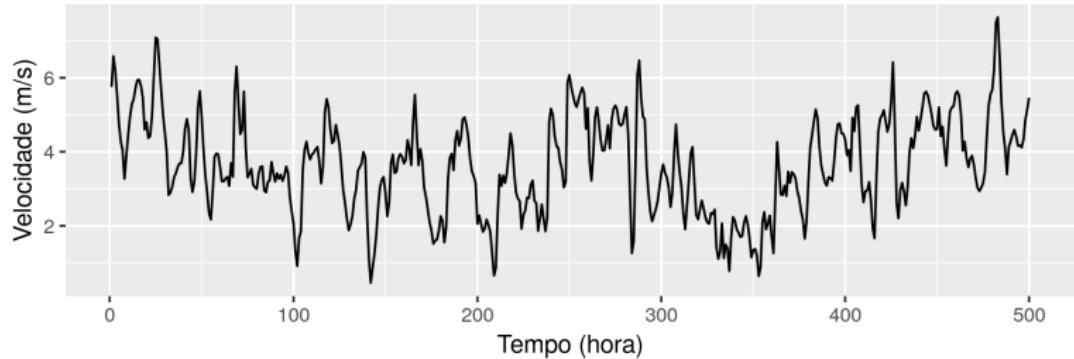
η = eficiência do conjunto gerador/transmissão

Curva de potência

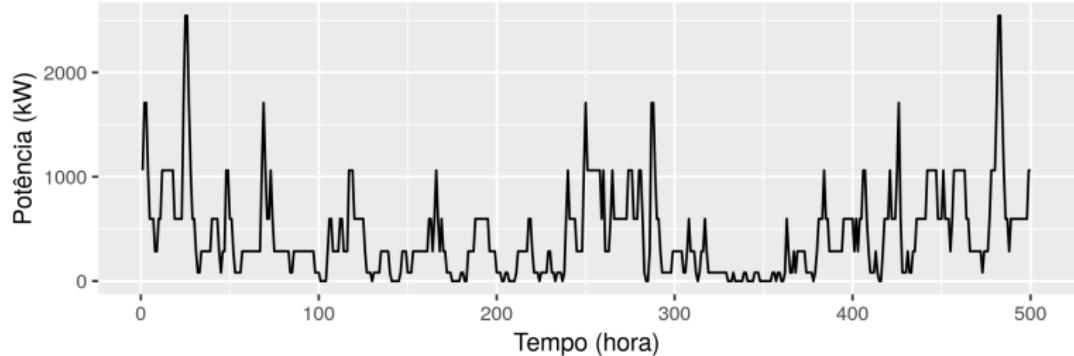


Mapeamento entre velocidade e energia

Velocidade do vento em base horária



Potência desenvolvida por uma turbina em base horária



Resultado e energia

500 horas de operação

- Produção máxima: 2250 MWh
- Produção prevista: 217 MWh
- Produção real: 212 MWh

O MWh custa, atualmente, cerca de 180 reais (CCEE)

Sumário

1 Introdução

2 Estudo de Caso

- Caracterização da região
- A série temporal modelo
- Caracterização dos dados

3 Implementação

- Box-Jenkins
- Modelo Autorregressivo Variável
- GARCH

4 Conclusão

- Conversão em energia
- Validação com outras séries

Validação: diferentes regiões



Validação: melhores resultados

Local	ME	RMSE	MAE	MPE	MASE
NE01a	0.0	0.02	0.01	-0.0	0.17
NE05	0.01	0.02	0.01	0.02	0.17
ChapadaAraripe	0.01	0.02	0.01	0.02	0.17
Embuaca	-0.01	0.02	0.02	-0.16	0.27
Santos	-0.01	0.02	0.02	-0.16	0.27
LaGuajira	0.03	0.04	0.04	0.25	0.27
AsaBranca	0.02	0.03	0.02	0.19	0.28
Omega	0.02	0.03	0.03	0.14	0.28
Icarai	-0.01	0.02	0.02	-0.19	0.29
EsquinaDoVento	0.03	0.04	0.03	0.25	0.4

Validação: piores resultados

Local	ME	RMSE	MAE	MPE	MASE
Omega_RJ	0.1	0.13	0.11	1.48	2.02
Ibipeba	-0.04	0.07	0.05	-1.83	2.11
Tafila ERA5	0.05	0.11	0.08	-0.19	2.33
CapaoAlto	0.0	0.07	0.06	-1.63	2.41
Quadran	-0.05	0.07	0.05	-2.48	2.61
LaVigia	-0.01	0.06	0.05	-2.28	3.12
Ckani	0.05	0.13	0.09	-0.95	3.35
SanPedro	0.08	0.17	0.12	-0.1	3.94
Tucano	-0.05	0.15	0.13	-3.74	4.8
Llanos	0.22	0.33	0.24	3.47	12.58